Proyecto de Investigación I

UNIDAD 3
ADQUISICION DE DATOS

ADQUISICION DE DATOS



Samuel Oporto Díaz

Tabla de Contenido

1. Objetivo

2. MEDICIÓN
   - Componentes de la Medición

3. SEÑALES
   - Señales

4. EXPERIMENTO
   - Experimento
   - Experimento en Analítica de Datos

5. PROTOCOLO DE EXPERIMENTACION
   - Protocolo de Experimentación

6. POBLACION Y MUESTRA
   - Población
   - Muestra

7. TAMAÑO DE LA MUESTRA
   - Tamaño de la Muestra

8. AUMENTADO DE DATOS
   - Aumentado de Datos

9. TIPOS DE MODELOS DE CLASIFICACION
   - Tipo de problema de clasificación

10. ETIQUETADO DE DATOS
    - Etiquetado de datos

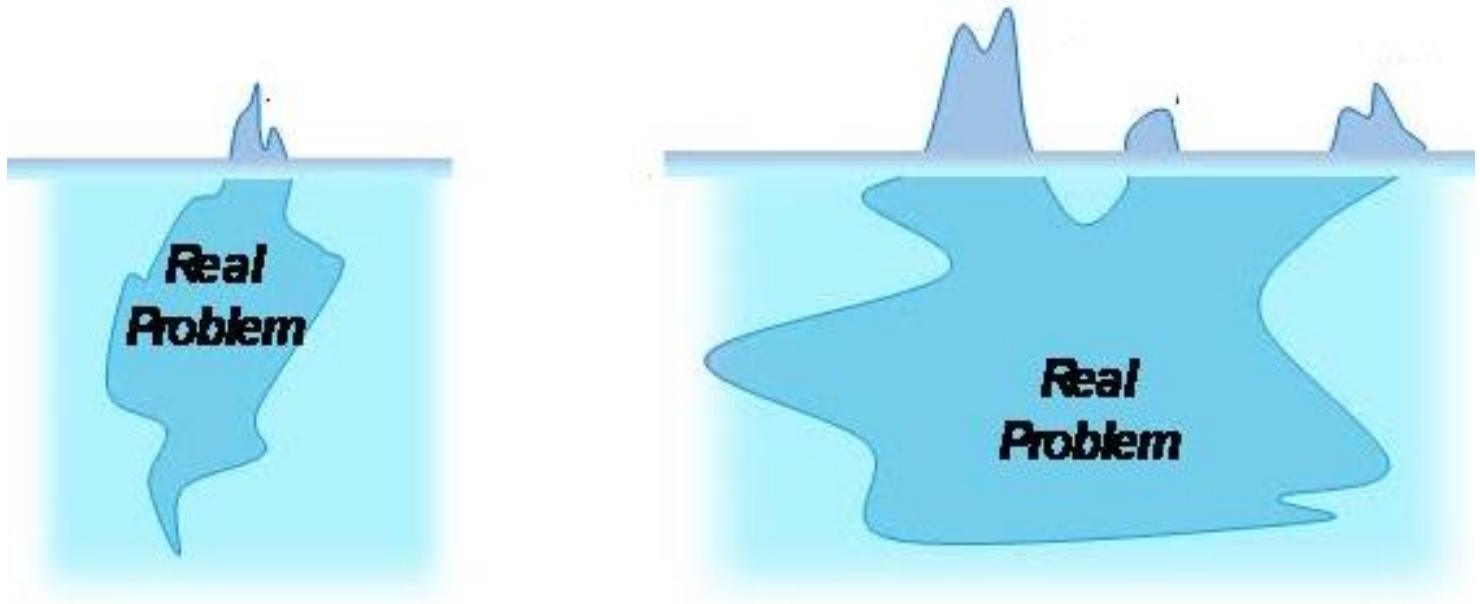
¿QUE ES UN PROBLEMA?



Ejercicio

¿Qué es un problema?

¿En el contexto de su proyecto de investigación, qué problema desea resolver?



Problema

Una **situación** que se desea transformar.

Pero para transformalo es necesario primero entender los **aspectos subyacentes** que la definen, la transformación requiere la **construcción de un artefacto** que ejecute los cambios.

Problema real

Problema abstracto

Problema tecnológico

La situación real.	**La situación subyacente.**	**La situación tecnológica.**	La necesidad del artefacto	La operación del artefacto.

NIVELES DE LA INVESTIGACIÓN BASADA EN DISEÑOS

Niveles de la Investigación

La investigación basada en diseño se orienta a crear **artefactos** para resolver **problemas** que ocurren en determinado **ámbitos**, para enfocarlo se consideran los siguientes niveles.

La situación real.	• Se percibe por los sentidos y el entendimiento humano. • Conocimiento tácito.
La situación subyacente.	• Caracteriza la situación subyacente <**objeto de estudio**> • Conocimiento explícito (ontológico)
La situación tecnológica.	• Se percibe mediante sensores/registros/encuestas. • Datos que representan la situación,
La necesidad del artefacto	• Artefacto para el procesamiento automático de los datos captados por los sensores/registros/encuestas
La operación del artefacto.	• Transformación de la realidad por el artefacto. • Procesa unidades de análisis <**objeto de estudio**>

Niveles de la Investigación

La situación real. | La situación subyacente. | La situación tecnológica. | La necesidad del artefacto | La operación del artefacto.

1 NIVEL 1 CONTEXTO

¿Dónde ocurre la situación?

Entorno en el que existe la oportunidad tecnológica. No describe aún el problema.

- Entorno
- Actores (agentes)
- Procesos existentes
- Recursos e infraestructura
- Normas, reglas y restricciones
- Cultura y organización

2 NIVEL 2 ASPECTOS SUBYACENTES DE LA SITUACIÓN

¿Qué características de la realidad justifican una intervención tecnológica?

Hechos, condiciones y características observables del contexto.
No son aún el problema.

- Propiedades del entorno
- Estados actuales
- Relaciones entre elementos
- Capacidades y limitaciones
- Variabilidad e incertidumbre
- Tecnologías y métodos disponibles

3 NIVEL 3 SITUACIÓN A MODIFICAR (PROBLEMA TECNOLÓGICO)

¿Qué condición actual se desea transformar mediante el artefacto?

Brecha entre el estado actual y el estado deseado, originada por la inexistencia del artefacto.

- Estado actual (sin artefacto)
- Estado deseado (con artefacto)
- Brecha o problema tecnológico
- Causa raíz: inexistencia del artefacto
- Objeto de transformación: la existencia y operación del artefacto

Ejercicio

Dado estos niveles de la investigación, donde se definen problemas. ¿En qué nivel se **resuelven** estos problemas?

Resolver un problema es la transformación intencional de un estado de realidad determinado y restrictivo en un estado configurado de forma óptima.

Es ejecutado por una **entidad consciente** que identifica la discrepancia y supera la resistencia intrínseca de los **elementos u objetos** que impiden esa transición.

Niveles de la Investigación

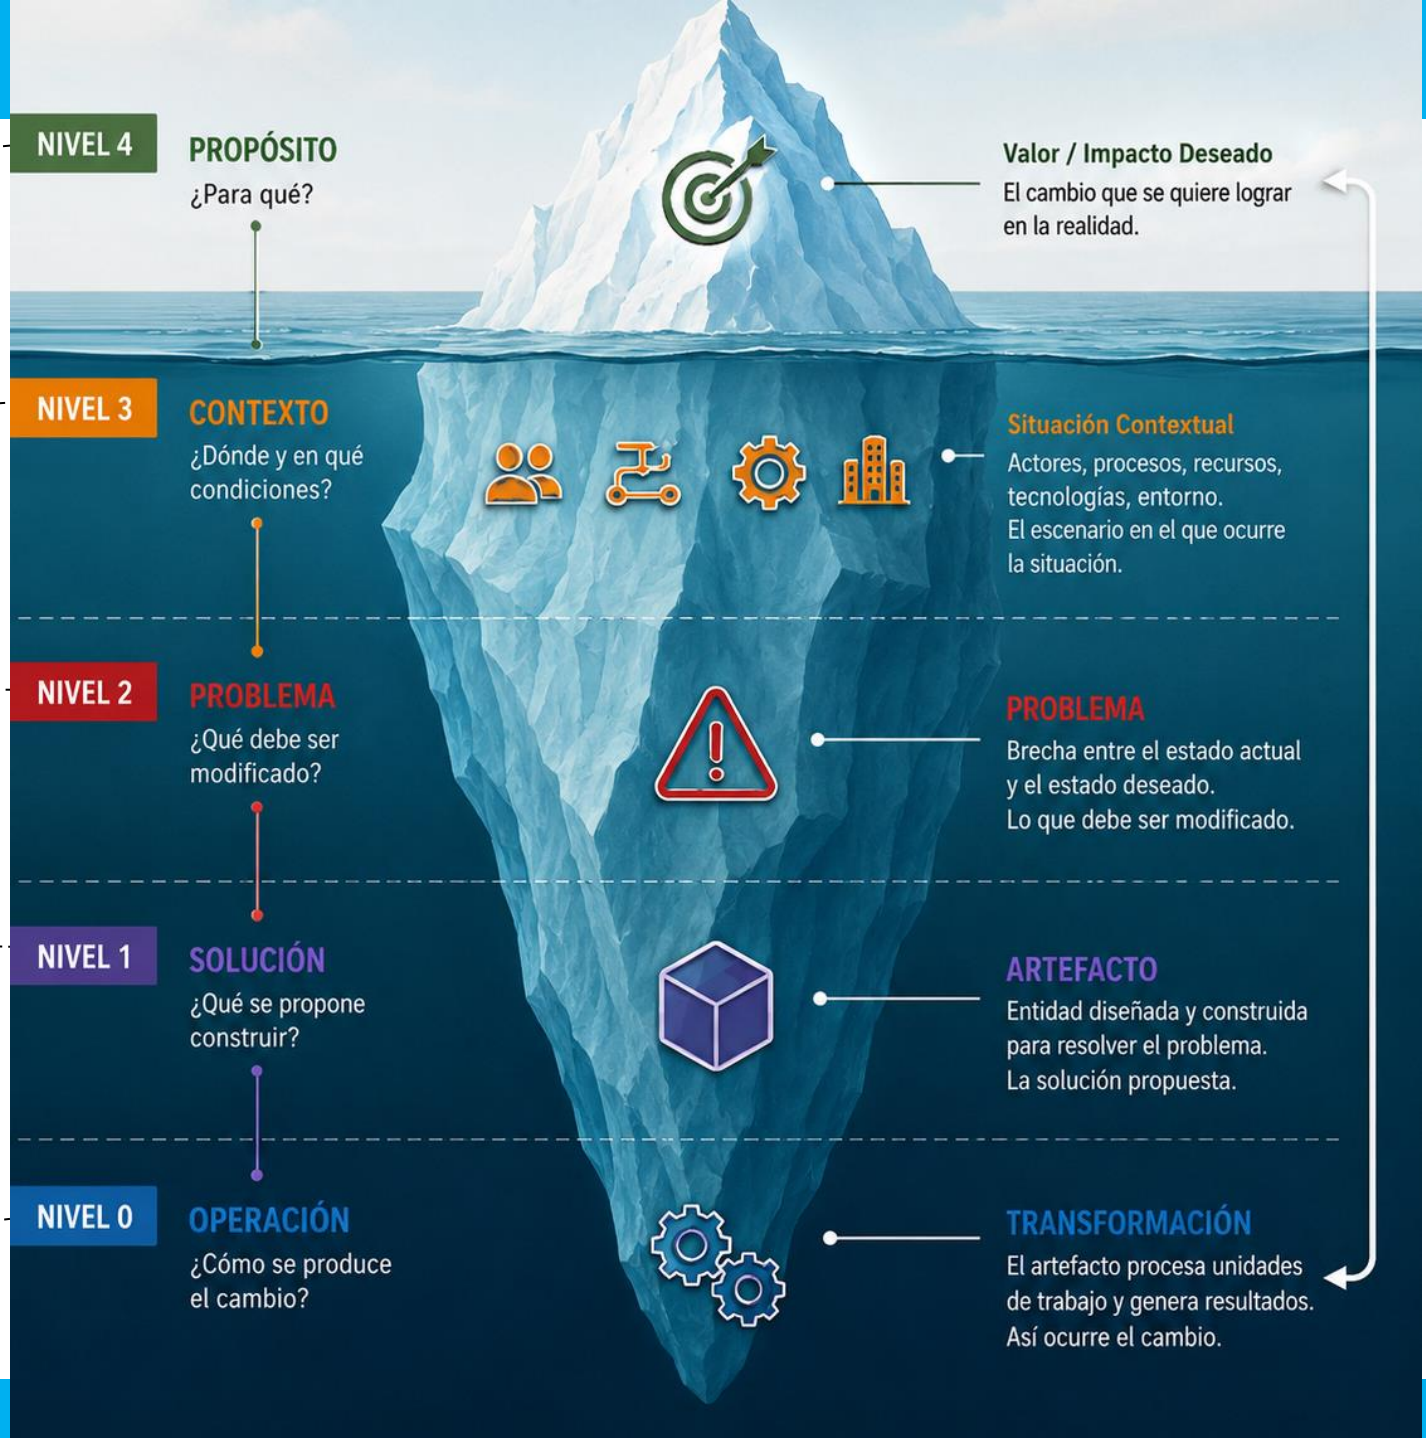
La situación real.

La situación subyacente.

La situación tecnológica.

La necesidad del artefacto

La operación del artefacto.



Ejercicio

- ¿Cómo y quién resolvería el **problema real**, si es que no se logra construir un artefacto que lo haga?

- ¿Cómo se resuelve el problema actualmente?

Ejercicio

- En qué secciones de su plan de tesis se exponen estos aspectos.

- *Listado de figuras*
- *Listado de tablas*
- *Listado de fórmulas/procedimientos.*

1. PLANTEAMIENTO DEL PROBLEMA
- Introducción
- Problemática
- Planteamiento del Problema
- Caracterización del Objeto de Estudio
- Alcances y Limitaciones.

2. OBJETIVOS DE LA INVESTIGACIÓN
- Objetivos
- Hipótesis
- Variables independentes (factores)
- Variables dependientes (resultados)
- Diseño experimental (factorial)

3. METODOLOGÍA DE LA INVESTIGACIÓN
- Metodología

4. MARCO TEÓRICO
- Antecedentes de la Investigación
- Bases conceptuales del problema
- Técnicas aplicadas
- Definición de términos

5. ANEXO
- Matriz de consistencia
- Matriz de operacionalización de variables
- Diseño Factorial (si corresponde).

La situación real.

La situación subyacente.

La situación tecnológica.

La necesidad del artefacto

La operación del artefacto.

MEDICIÓN


AIR QUALITY (NO2)
LIVE DATA STREAMS
STREET-LEVEL SENSORS (AURA_04, ESP_11)
DATABASE: TRAFFIC FLOW (CITY_09)
COMMUNITY FEEDBACK SURVEYS (422 responses today)
URBAN SENSORS

Medición

Una **medición** es cualquier conjunto de datos obtenidos mediante un sensor o método de observación que representan, directa o indirectamente, el estado de una o más variables del sistema, y puede adoptar formas **escalares, vectoriales, matriciales o tensoriales**, incluyendo series de tiempo.

Una **medición** es el resultado de observar una o más características de un sistema o fenómeno mediante **instrumentos o sensores**, y puede expresarse en diversas formas: desde un valor escalar hasta estructuras complejas como **vectores, matrices o tensores multidimensionales**.

Estas estructuras pueden, además, tener una **naturaleza temporal** (es decir, pueden variar a lo largo del tiempo).

Componentes de la Medición

1. **Variable a medir**
   temperatura, longitud, tiempo, nivel de calidad, concentración, vibración

2. **Instrumento o método de medición**
   termómetro, regla, cronómetro, cuestionario, cámara, lidar, base de datos.

3. **Unidad de medida**
   Ejemplo: metros, segundos, grados Celsius, porcentaje.

4. **Frecuencia o momento de la medición**
   ¿Cuándo se mide? ¿Con qué frecuencia?

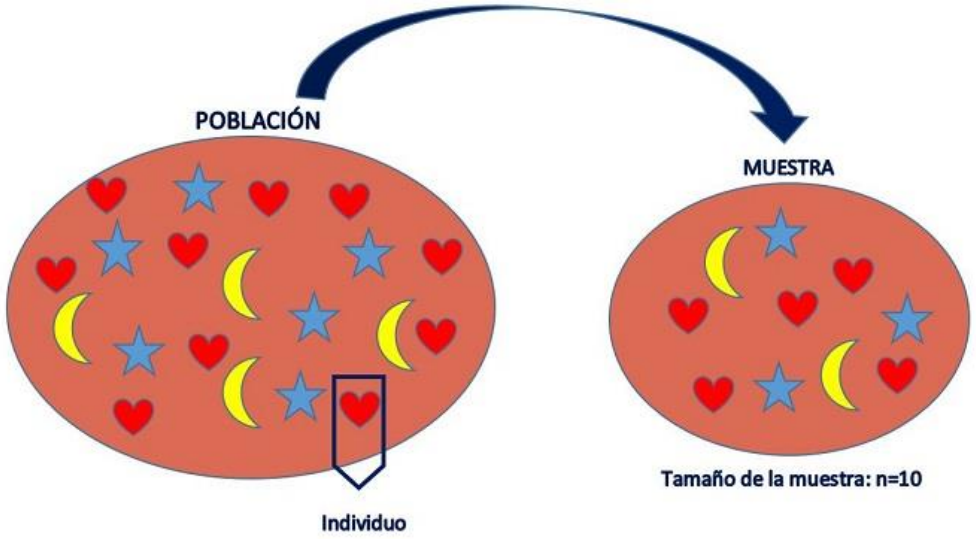
5. **Escala de medición**
   1. **Nominal**: categorías sin orden (ej. color, tipo de falla).
   2. **Ordinal**: categorías con orden (ej. bueno/regular/malo).
   3. **Intervalo**: rangos
   4. **Razón**: números con cero real (ej. longitud, peso, número de fallas).

5. **Canales**
   Número de sensores en paralelo

5. **Dimensiones**
   Cuanto valores se extrae en un sola medida (vector)

5. **Error**
   Calidad de la medición.

POBLACION Y MUESTRA



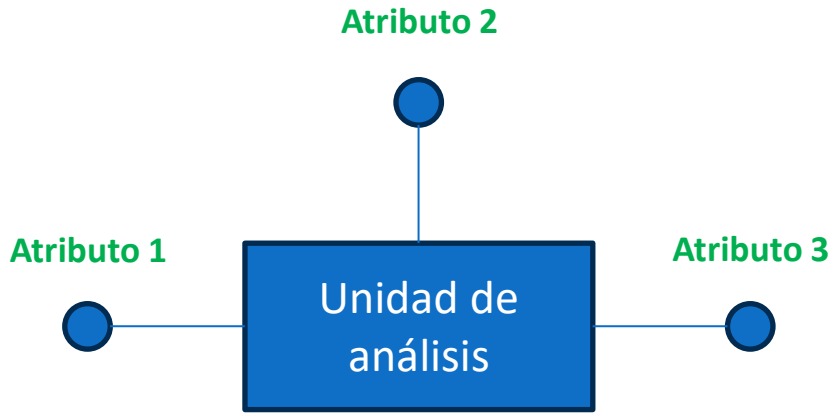
Ejercicio

Determine la población y la muestra y el tamaño de la población y de la muestra:

1. Se desea investigar los hábitos de estudio de los estudiantes de ingeniería de una universidad. El estudio se basará en encuestas aplicadas a una parte de estos estudiantes, al inicio y fin de cada ciclo, durante 7 años.
2. Se desea construir un modelo para clasificar imágenes de frutas (manzanas, plátanos, naranjas), de tal forma que se pueda conocer el estado de madurez de ellos.
3. Se desea analizar la calidad del aire en distintas zonas de una ciudad mediante sensores que se instalan en ubicaciones fijas de la ciudad - Se mide: temperatura, presión, precipitación, CO_2, velocidad viento, radiación solar, durante 1 año.
4. Se desea crear un modelo que relacione la frecuencia de la luz y el crecimiento de plantas. Se tiene 150 plantas sembradas, pero se medirá solo 30 de ellas durante un mes.
5. Se desea correlacionar el número de denuncias reportadas y registradas sobre violencia domestica, en las comisarias en el departamento x, con el nivel de ingresos y el grado de estudios de los participantes.

Población

Población.
Es el **conjunto completo** de **medidas** efectuadas a una o más **características** y sobre los cuales se desea obtener información o hacer inferencias, de **unidades de análisis**.



1. Las **unidades de análisis** pueden ser objetos físicos, eventos, registros, procesos, decisiones, operaciones, fenómenos, etc.

2. Una instancia de **medida** corresponde a un individuo de la población.

3. Cada unidad de la población es una medida efectuada al atributo o característica que se desea.

4. La población puede ser finita o infinita, pasada, presente o futura, observable o hipotética.

1. finita o infinita
2. pasada, presente o futura
3. observable o hipotética.

Muestra

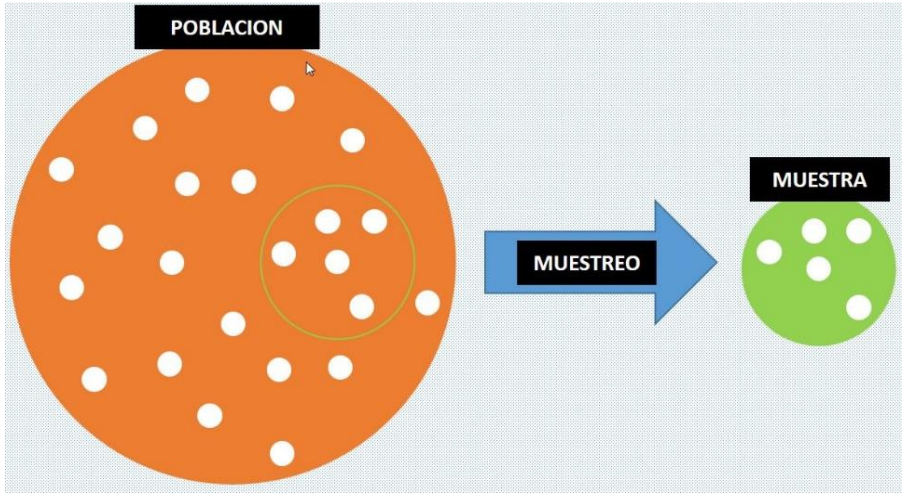
Muestra

La muestra es un **subconjunto representativo de la población**, seleccionado con el objetivo de estudiar sus características y, a partir de ella, hacer inferencias sobre la población entera.

Se usa cuando es imposible, costoso o innecesario estudiar toda la población.

Debe seleccionarse de manera que represente adecuadamente a la población (usando técnicas como muestreo aleatorio, estratificado, etc.).

- La muestra debe estar formada por unidades representativas de la población.
- Puede seleccionarse mediante diferentes técnicas (aleatoria, estratificada, por conveniencia, etc.).
- El objetivo es extraer conclusiones generalizables a la población, minimizando el sesgo y maximizando la precisión.



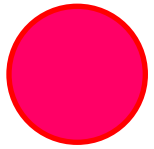
Ejercicio

- ¿Cuál es la diferencia entre población y muestra?

- ¿Se puede conocer la población?

¿Unidad de Análisis?

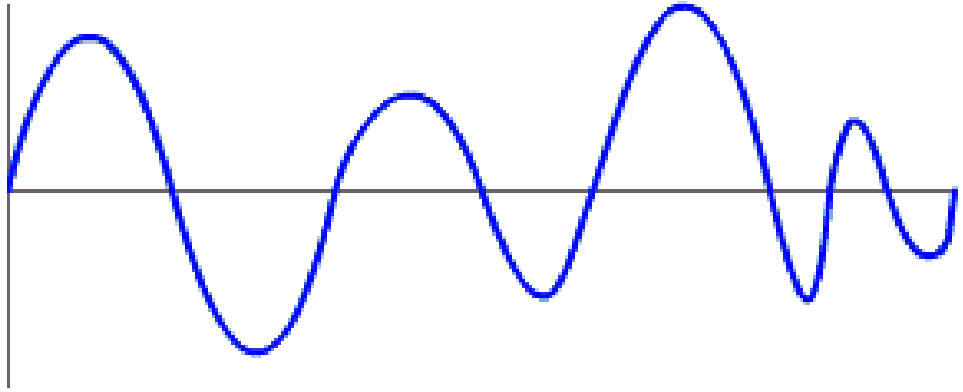
- Cuál es la **unidad de análisis** de su **proyecto de investigación / innovación**.
- Cómo se relaciona la **unidad de análisis** con el **objeto de estudio**.
- Cómo se relaciona la **unidad de análisis** con el **problema de estudio**.
- Caracterice la **unidad de análisis** de proyecto de investigación.
- Presente ejemplos concretos de la **unidad de análisis**.



SEÑALES

Señales

- Una señal es el registro de una magnitud física tomado desde el objeto que la origina (es un dato).
- El registro corresponde al comportamiento de un atributo, característica o cualidad del objeto de estudio al que se le denominará variable.
- Las señales se representan por el «ploteo» de sus valores en el tiempo S(t).

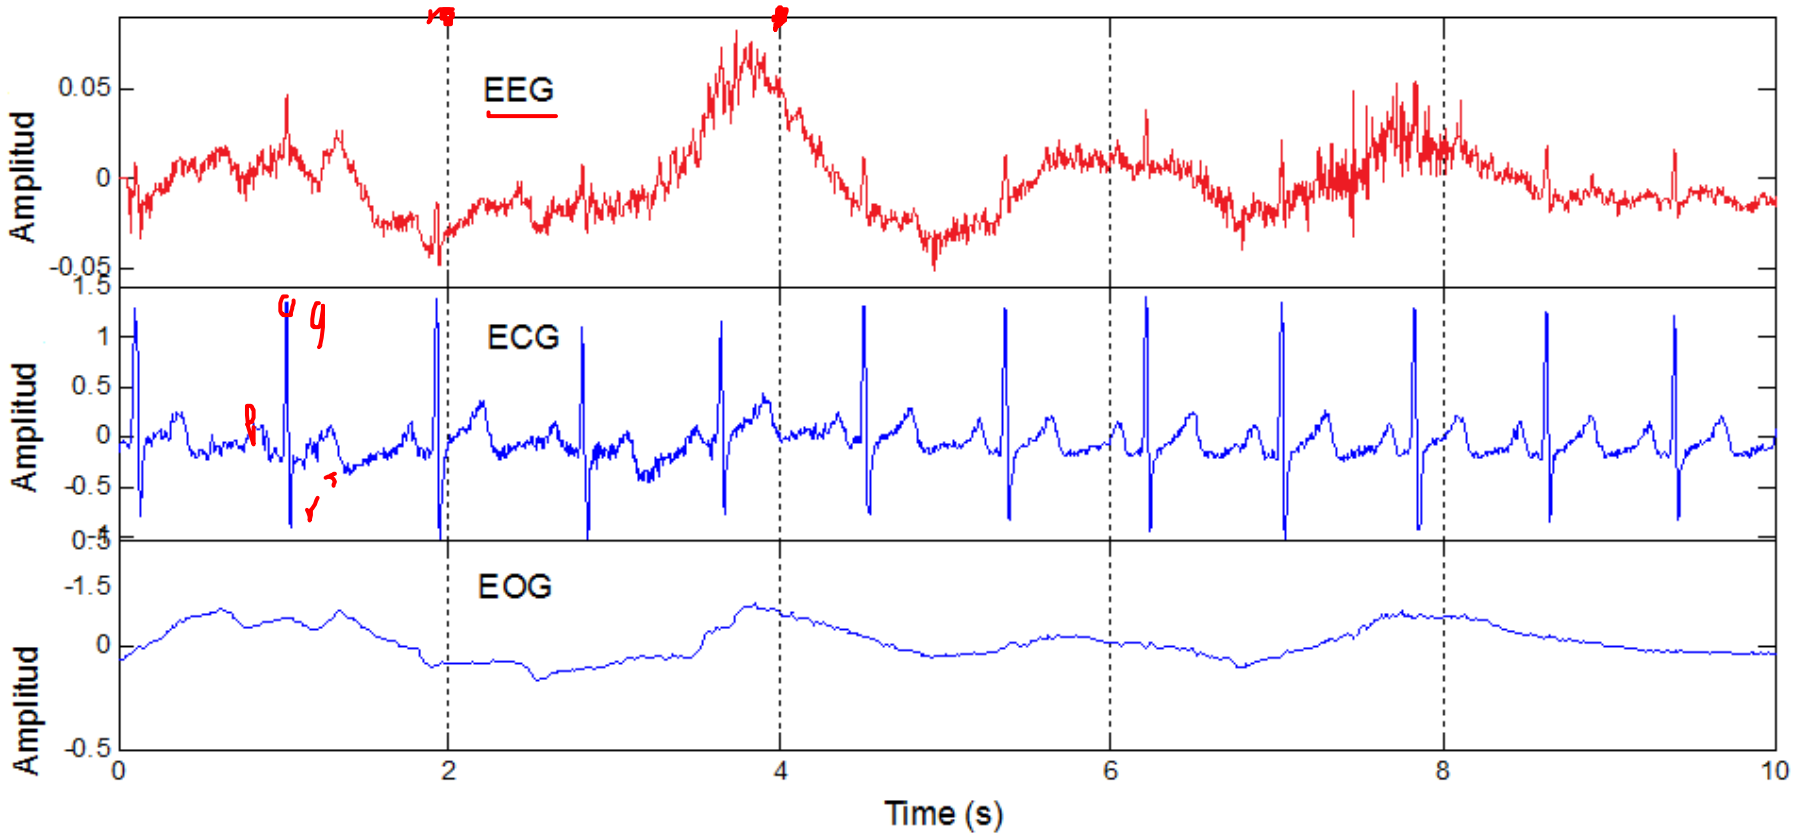


- Las señales contienen información significativa acerca del comportamiento del objeto de estudio, de tal forma que si se pueden medir continuamente se puede conocer continuamente el estado del objeto de estudio.

Señales

- Cada señal mide una característica particular del objeto en estudio de tal forma que la representación de la característica tiene un patrón de comportamiento propio que permite diferenciarlo de otras características del objeto en estudio.

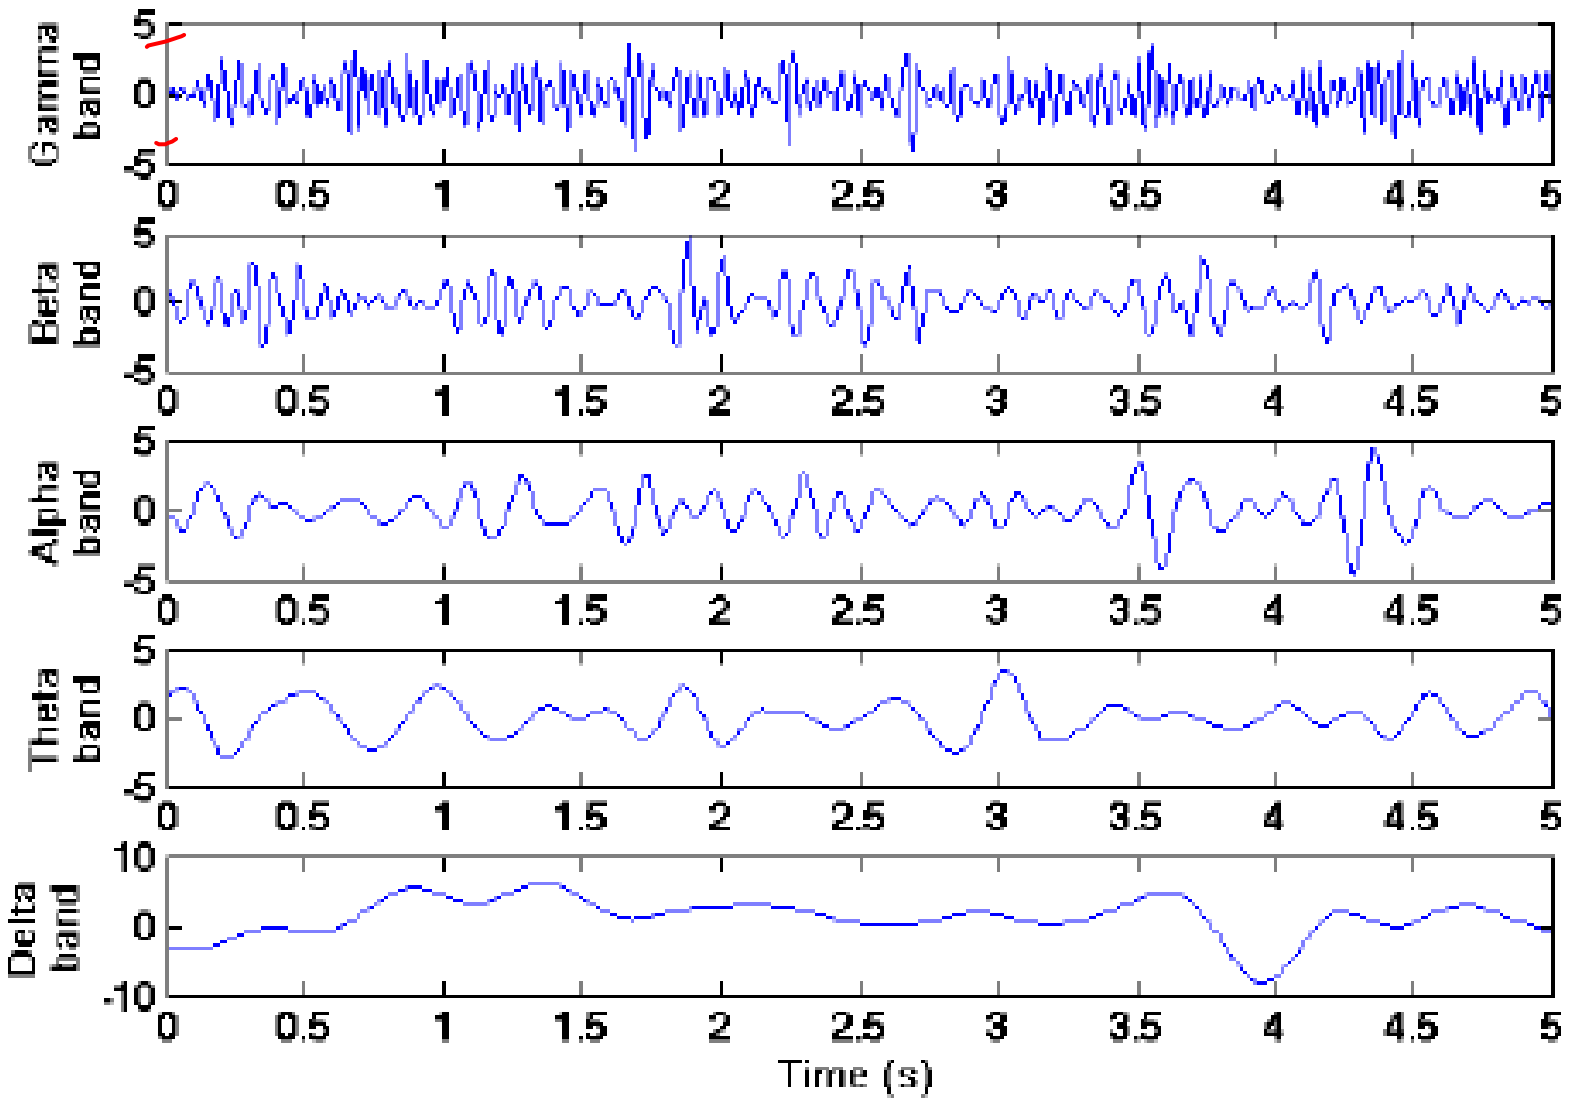
EEG: electro encefalograma ECG: electro cardiograma EOG: electro oculograma



Señales

De una señal puede interesar:

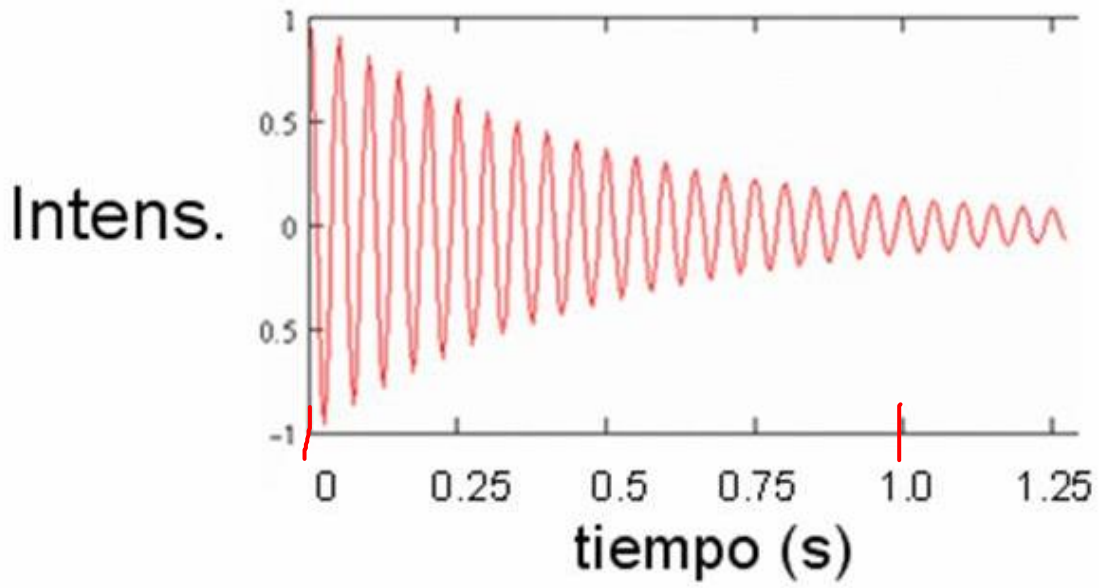
- Su estado.
- La cantidad de cambios de estados.
- Su nivel.
- Su forma.
- Su frecuencia.



Señales

- Una señal se expresa como una función con un dominio y un rango.

- La variable independiente es el conjunto de valores para los cuales la señal está definida (dominio) y la variable dependiente es la magnitud que se mide (rango).



Señales

Dimensiones

Unidimensional

si una señal es una función de una variable independiente única, por ejemplo el tiempo.

Multimensional

Si una señal es una función de N variables independientes, por ejemplo una imagen I(x,y), pero si se trata de un video, la señal es representada como I(x,y,t), donde el brillo del pixel (x,y,t) es una función del espacio y del tiempo.

Canales

Monocanal

Cuando la señal está conformada por la medición de una sola magnitud S(t), por ejemplo la temperatura.

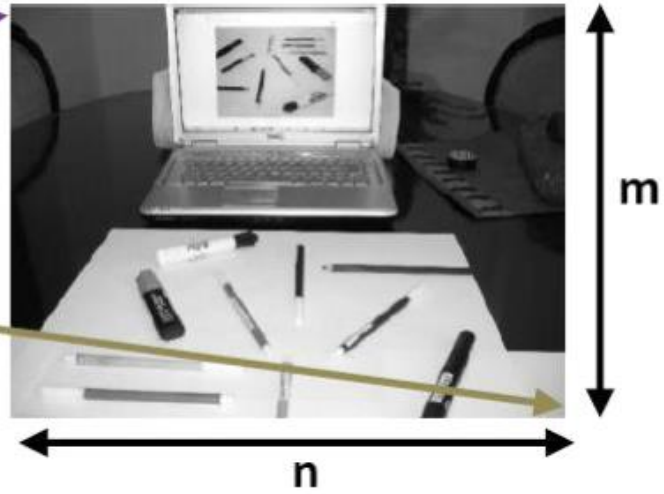
Multicanal.

Cuando la señal esta conformada por la medición de múltiples magnitudes simultáneamente (con múltiples sensores), por ejemplo la salida de un electrocardiograma que tiene 3 electrodos puede ser representada como un vector S3(t)= (s_1 (t), s_2 (t), s_3 (t))

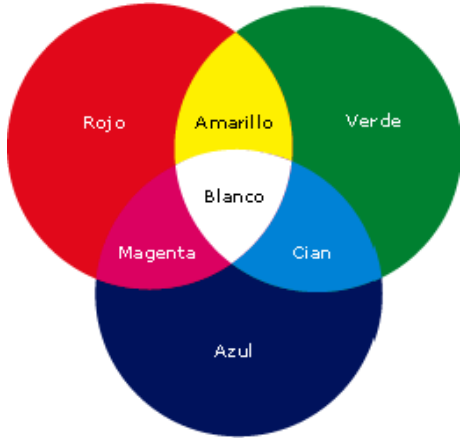
Imágenes

- Son bidimensionales:

$$I(x,y) = \begin{bmatrix} V_{11} & \cdots & V_{1n} \\ \vdots & \ddots & \vdots \\ V_{m1} & \cdots & V_{mn} \end{bmatrix}$$



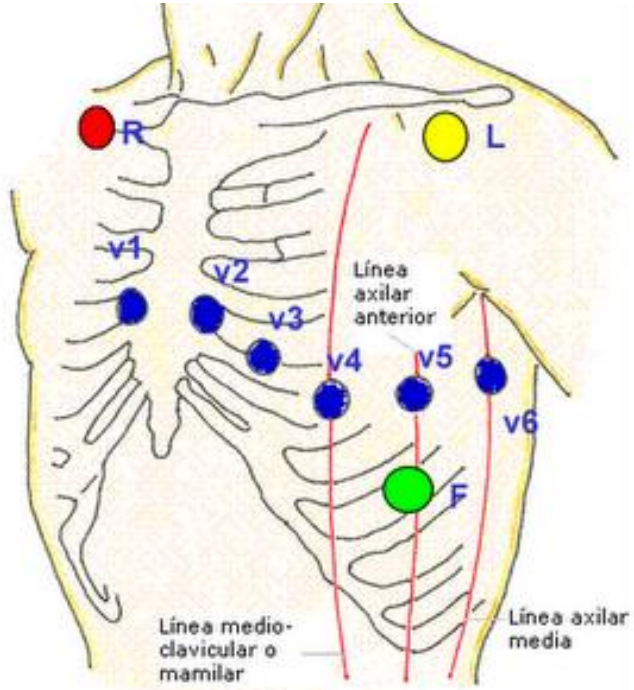
- Son multicanal



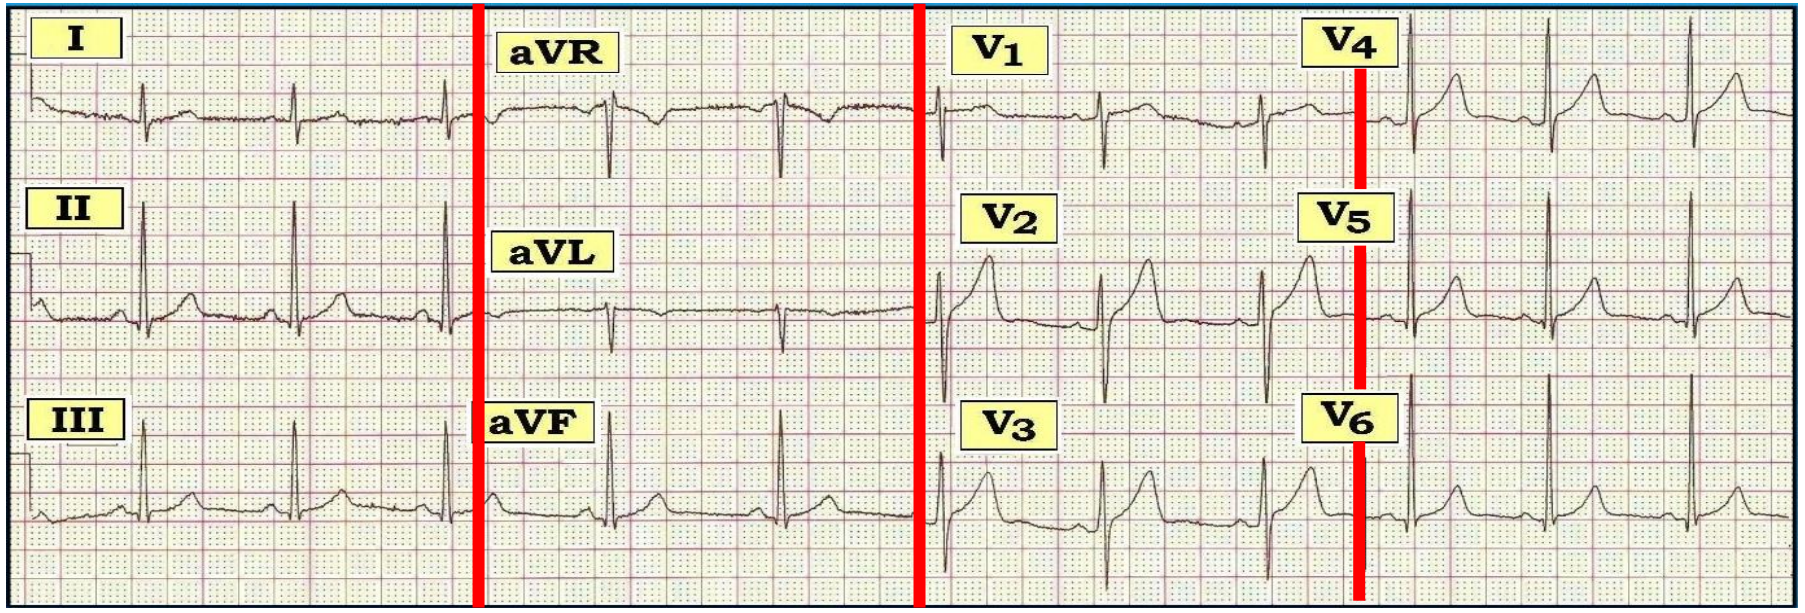
$$V_{11} = \begin{bmatrix} R \\ G \\ B \end{bmatrix}$$

Señales

- Electrocardiograma, es una señal multicanal.
- S = $[I, II, III, aVR, aVL, aVF, V_1, V_2, V_3, V_4. V_5, V_6]$

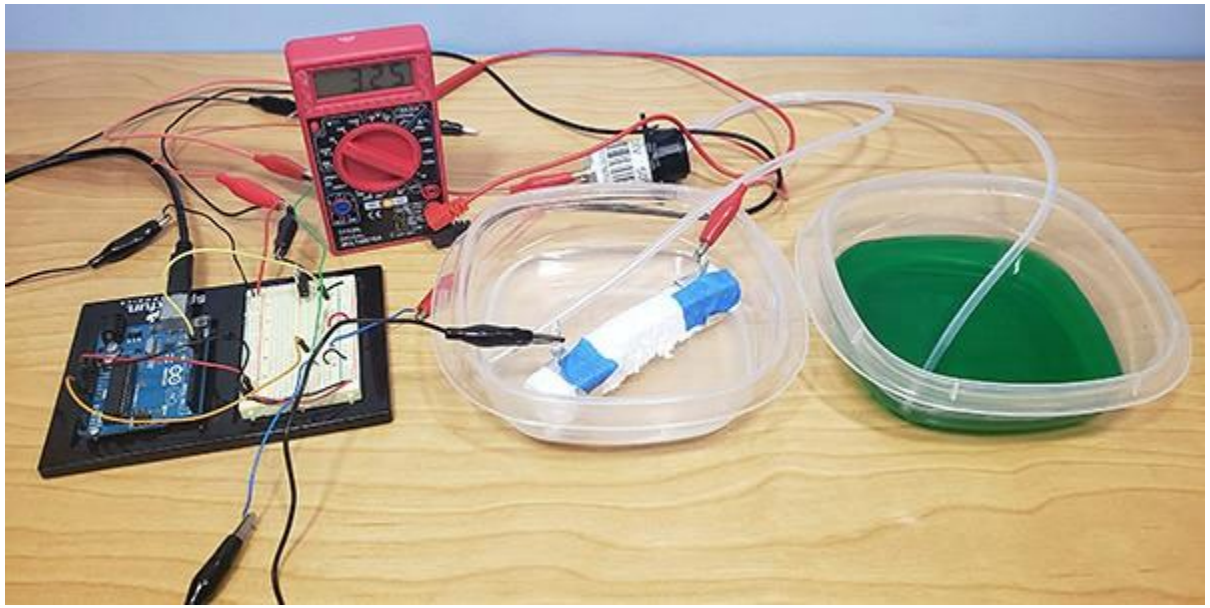


Localización de los electrodos correspondientes a las derivaciones precordiales V1 a V6



www.physionet.org

EXPERIMENTO



Experimento

Un **experimento** es un **procedimiento controlado** y sistemático que se realiza con el objetivo de **observar, medir o comprobar** una hipótesis, causa-efecto o comportamiento bajo ciertas condiciones.



Un **experimento** consiste en:

- Manipular **una o más variables independientes** (factores que el investigador controla).

- Observar el efecto que esto tiene sobre **una o más variables dependientes** (resultados que se miden).

- Mantener constantes las demás condiciones para evitar sesgos.

Experimento

Encuesta / Sensores / Base de Datos / Documentos

Variables independientes de la investigación **(factores)**

Estímulo



Resultado

Medida de los resultados experimentales

Variables dependientes de la investigación

Registro del Experimento

Aumentación de Datos

Ejemplo

Sistema estudiado	Carretera
Objeto de Estudio	Segmento de la capa asfáltica.
Unidad análisis	Imágenes de secciones de pavimento tomadas con dron o cámara a pie de vía
Variables controladas	Iluminación, resolución de cámara, altura de toma, condiciones climáticas
Variables no controladas	Luz solar, polvo del ambiente
Instrumento de medición	Cámara Espectro Visible
Característica medición	Matriz con niveles de grises, 3 canales, se considera el tiempo
Tamaño de muestra	300 imágenes etiquetadas por expertos (100 por categoría)
Variable independiente (factor)	[Base de Datos de Img. Ya disponible, muestrea de las imágenes]
Variable dependiente	Representatividad de la realidad.
	Estado real del pavimento (etiquetado: buena, regular, mala)
	Imagen tomada con la cámara

Experimento en Analítica de Datos

En el contexto de la **analítica de datos**, un experimento consiste en:

- **Diseñar experimentos** para la extracción de características desde las unidades de análisis, para los que se requiere definir parámetros controlables, seleccionar parámetros no controlables.

- **Recolectar datos** de forma estructurada/no estructurada, ya sea mediante observación directa, sensores, encuestas, simulaciones u otras fuentes.

- **Almacenar los datos** según su formato.

- **Controlar las condiciones** bajo las cuales se recogen los datos [parámetros].

- **Limpieza de los datos, aumentación de datos, etiquetado de datos.**

- **Analizar los resultados** con técnicas estadísticas o computacionales para extraer conclusiones significativas.

Ejercicio

Para su proyecto de tesis, determinar:

- Sistema estudiado (entorno)
- Objeto de Estudio
- Unidad análisis
- Características de la unidad de análisis

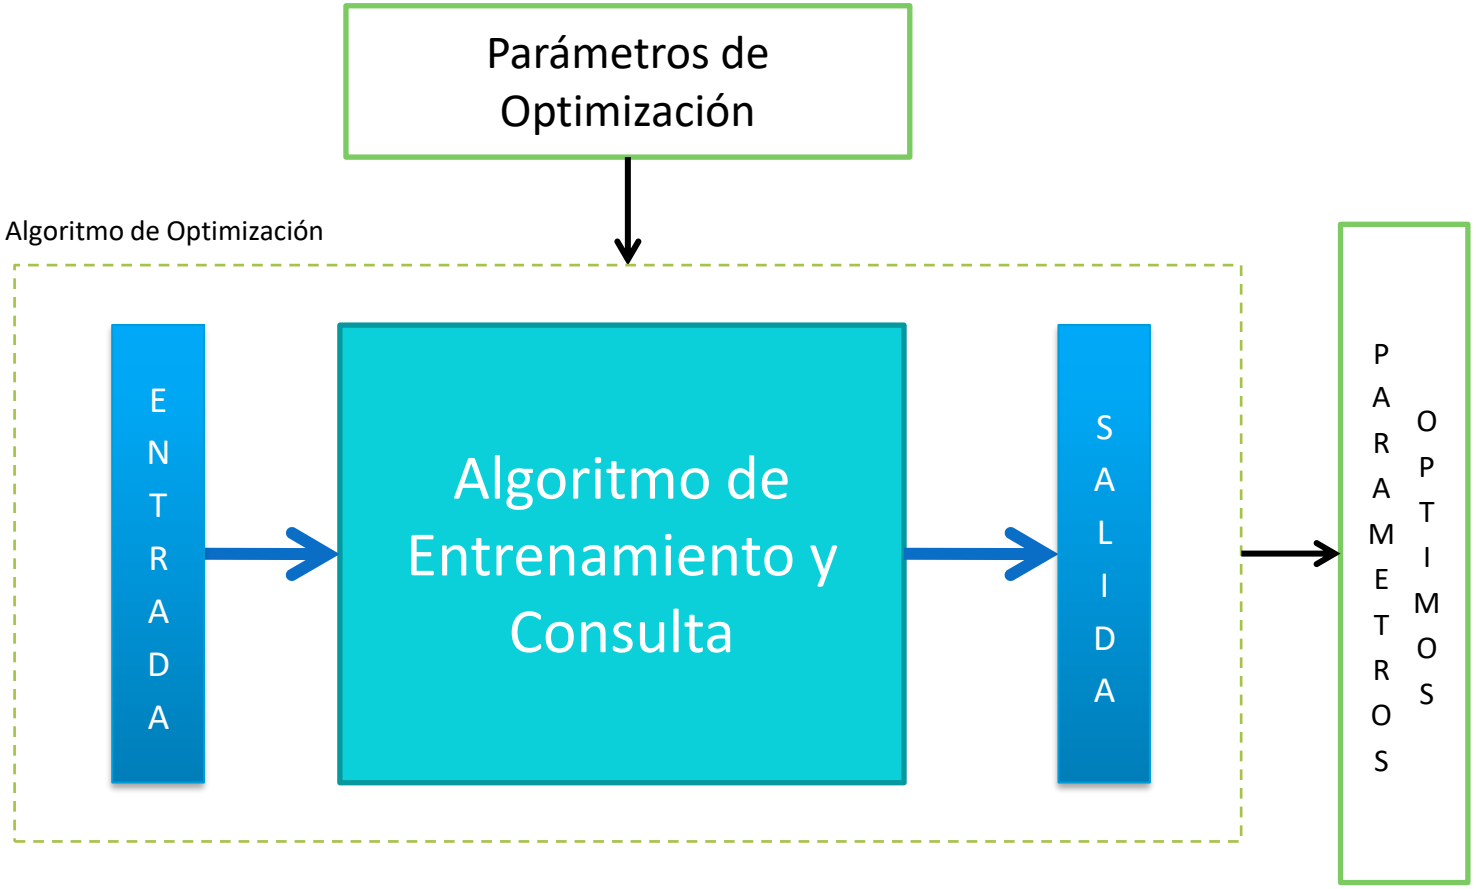
Unidad de Análisis

- Variables controladas (parámetros controlables)
- Variables no controladas (parámetros no controlables)
- Instrumento de medición [canales; dimensiones]
- Tamaño de la muestra
- Formato almacenamiento; bytes por unidad

Investigación

- Variables independiente (factores [categóricas])
- Diseño factorial (diseño experiemental)
- Variables dependientes (medida de resultados [numéricas])

Variables, Parámetros



PROTOCOLO DE EXPERIMENTACION

Protocolo de Experimentación

Es una guía escrita que especifica todos los pasos, materiales, condiciones, variables, criterios de medición y procedimientos de análisis que se deben seguir durante un experimento.

1. Determinar el instrumento de captura de datos.
2. Disponer de la Infraestructura técnica para el DAQ.
3. Definir las condiciones de registros de los resultados del experimento.
4. Determinar el tamaño y representatividad de la muestra.
5. Etiquetar la muestra [exante o expost]
6. Identificar los aspectos éticos y legales [Ley N° 29733, Ley de Protección de Datos Personales].
7. Evaluación del desempeño del sistema.

Protocolo de Experimentación

1. Determinar el instrumento de captura de datos.
   Qué sensores se usaran, en el proceso, canales, dimensiones, tiempo.

2. Infraestructura técnica.
   Establece las fuentes de alimentación, el DAQ, el equipo de almacenamiento, los protocolos de comunicaciones, etc.

3. Condiciones de captura de los datos.
   Factores ambientales, hora, vibración, distancia, interferencias, etc.
   ¿representatividad y expresividad del muestreo?

4. Tamaño y representatividad de la muestra.
   El tamaño de la muestra es adecuada, existe sesgo, es significativa.

5. Etiquetado de la muestra.
   A qué categorías pertenece cada instancia de las muestras [exante][expost]

6. Aspectos Éticos y Legales.
   Incumple la Ley N° 29733, Ley de Protección de Datos Personales

7. Evaluación del desempeño del sistema.
   Falsos positivos, falsos negativos, sesgo

TAMAÑO DE LA MUESTRA

Tamaño de la Muestra

Es un proceso estadístico que determina cuántas observaciones (datos) se necesitan recopilar para que los resultados del análisis sean **confiables**, **representativos** y **estadísticamente significativos** respecto a una población más grande.

Es **cuántas unidades** vas a observar, medir, encuestar o analizar **de una población más grande**, con el objetivo de obtener conclusiones representativas **sin estudiar a toda la población**.

Confiable	Representatividad	Significancia estadística
Implica que los resultados obtenidos pueden **repetirse** si se toma otra muestra en las mismas condiciones. Para lograrlo: 1. Usa métodos de muestreo probabilístico (como muestreo aleatorio simple o estratificado). 2. Minimiza errores de medición o sesgos. 3. Asegúrate de que el instrumento (ej. encuesta) esté bien diseñado.	Una muestra es representativa si **refleja adecuadamente las características de la población**. Para ello: 1. Elige la muestra de forma aleatoria y sin sesgo. 2. Considera las variables clave (por ejemplo: edad, sexo, nivel socioeconómico). 3. Si hay subgrupos importantes, puedes usar muestreo estratificado para que todos estén incluidos proporcionalmente.	Se refiere a que **los resultados no sean producto del azar**, y se puedan **generalizar** con cierto nivel de confianza. Depende principalmente de: 1. El tamaño de la muestra: mientras mayor, menor el error. 2. El nivel de confianza deseado (ej. 95%). 3. El margen de error aceptado (ej. ±5%). 4. La variabilidad de los datos (más variación requiere una muestra más grande).

Tamaño de la Muestra

El tamaño de la muestra se calcula en función de varios factores:

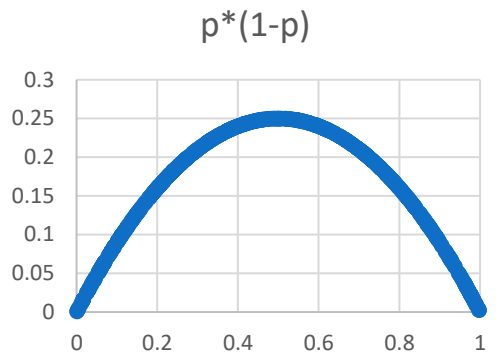
1. el tamaño de la población

2. el nivel de confianza deseado
   *Indica **qué tan seguro** estás de que los resultados de tu muestra representan a la población total.*

Nivel de confianza	Área acumulada	Valor Z
90%	0.95	1.645
94%	0.97	**1.88**
95%	0.975	1.96
99%	0.995	2.576

3. el margen de error aceptable
   indica el rango dentro del cual se espera que esté el verdadero valor de la población respecto a la estimación obtenida en la muestra.

4. la variabilidad de los datos
   Indica qué tanto **varían o se dispersan** los valores dentro de la población que estás estudiando, es una estimación de la STD.



Tamaño de la Muestra

$$n = \frac{Z^2 \cdot p \cdot (1-p)}{e^2}$$

Donde:

- n = tamaño de la muestra
- Z = valor z según el nivel de confianza:
  - 90% → 1.645
  - 95% → 1.96
  - 99% → 2.576
- p = proporción esperada de éxito (si no se sabe, usar 0.5 porque da el tamaño máximo)
- e = margen de error (en decimales, por ejemplo 5% = 0.05)

- Nivel de confianza: 95% → Z=1.96
- Proporción esperada: 0.5 (si no se sabe)
- Margen de error: 5% → e=0.05

$$n = \frac{1.96^2 \cdot 0.5 \cdot (1-0.5)}{0.05^2} = \frac{3.8416 \cdot 0.25}{0.0025} = \frac{0.9604}{0.0025} = 384.16$$

- Se necesitan aproximadamente 385 muestras para una población muy grande.

Ejercicio

Sea un problema de clasificación binaria de imágenes, ¿cuál es el tamaño de muestra significativo que se debe de tomar para entrenar un modelo de aprendizaje?

¿Este tamaño es por cada estado de la clase o para toda la muestra?

¿Qué sucede si los datos están desbalanceados?

¿Qué sucede si las imágenes tienen alta complejidad? [no es posible eliminar el fondo]

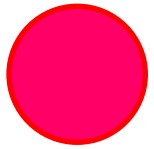


Ejercicio

Si vas a entrenar un modelo desde cero, necesitarás una gran cantidad de imágenes, especialmente si las imágenes tienen alta variabilidad.

Recomendación:≥ 1000 imágenes por clase (mínimo 2000 imágenes en total)

Idealmente más (5000+ por clase) para problemas complejos



AUMENTADO DE DATOS

Aumentado de Datos

Data Augmentation (aumento de datos) es una técnica utilizada en machine learning y especialmente en visión por computadora, que consiste en crear nuevas muestras artificiales a partir de tus datos reales, aplicando transformaciones aleatorias que no cambian la clase de la imagen.

¿Para qué sirve el data augmentation?

- Aumenta la cantidad de datos sin recolectar más imágenes/señales/nubes de puntos
- Mejora la capacidad de generalización del modelo
- Reduce el sobreajuste (overfitting)
- Es esencial cuando tienes pocas muestras.

Técnicas – procesamiento de imágenes

Tipo de transformación	Descripción breve
Rotación	Gira la imagen algunos grados
Traslación	Mueve la imagen en X o Y
Escalado	Agranda o achica la imagen
Recorte (crop)	Recorta una parte aleatoria de la imagen
Inversión (flip)	Voltea horizontal o vertical
Ajuste de brillo	Ilumina u oscurece la imagen
Ajuste de contraste	Modifica la intensidad del contraste
Ruido aleatorio	Agrega pequeños puntos o grano a la imagen
Desenfoque (blur)	Aplica un desenfoque leve a la imagen
Cambio de color	Modifica tonos, saturación, etc.

Técnicas – procesamiento de señales

Técnica	Descripción	Aplicación Ejemplo
Ruido añadido	Añadir ruido blanco o gaussiano para simular variabilidad	Señales de audio o acelerómetro
Desplazamiento temporal	Mover la señal hacia adelante o atrás en el tiempo	Series temporales, audio
Escalamiento de amplitud	Multiplicar la señal por un factor cercano a 1	Cambiar volumen o intensidad
Estiramiento/Compresión	Cambiar velocidad sin alterar frecuencia	Audio, simulación de velocidad
Recorte/Segmentación	Extraer ventana temporal aleatoria	Señales largas, análisis local
Interpolación/Padding	Añadir o eliminar muestras para cambiar longitud	Ajustar tamaño de la señal
Inversión temporal	Leer la señal al revés	Solo si no altera la clase
Transformación en frecuencia	Modificar espectrograma o componentes frecuenciales	Audio, señales transformadas
Distorsión no lineal	Aplicar deformaciones suaves o funciones no lineales	Variaciones complejas
Cambio de fase	Modificar la fase en el dominio de frecuencia	Ajustes finos en señales periódicas
Pitch Shifting (audio)	Cambiar altura tonal sin variar duración	Voz, música
Reverberación y eco	Añadir efectos ambientales para simular diferentes entornos	Audio ambiental

Ejercicio

- Para su proyecto de investigación qué técnicas de aumentado de datos, sería factible usar.

- Si este fuese el caso ¿Cuántas muestras cómo mínimo son necesarias para la construcción de un modelo?

TIPOS DE MODELOS DE CLASIFICACION

Tipo de problema de clasificación

- Un **problema de clasificación** es una tarea dentro del aprendizaje automático (machine learning) donde el objetivo es asignar una [etiqueta, categoría, estado] a cada ejemplo o dato de entrada, basándose en sus características o atributos.

- El tipo **de problema de clasificación**, es la **forma cómo están organizadas o definidas las [**categorías, etiquetas**]** que queremos predecir, y cómo se relacionan con los datos.

- Según la naturaleza y la cantidad de esas categorías, y cómo se asignan a las instancias de datos (unidad de análisis), se clasifican los problemas en distintos tipos.



Conceptos

Concepto	Definición
Target	Variable que se desea predecir (una columna)
Conjunto de clases	Todos los valores posibles del target (estados)
Clase	Un valor posible del target asignado a una instancia de datos, también se le puede denominar un estado.
Etiqueta (Label)	La clase asignada a una observación particular.

Tipo de Problema de Clasificación

TARGET
Variable que el modelo debe predecir.

CLASE
Cada valor posible que puede tomar el target.

ETIQUETA (LABEL)
Valor de la clase que tiene una instancia específica.

1. BINARIO

Un solo target con dos models posibles.

Ejemplo: Fraude



- 1 target
- 2 clases
- Clases excluyentes
- Solo una clase posible por instancia

2. MULTICLASE

Un solo target con más de dos clases posibles. Solo una clase es posible por instancia.

Ejemplo: Color



- 1 target
- > 2 clases
- Clases excluyentes
- Solo una clase posible por instancia

3. MULTIETIQUETA (MULTI-LABEL)

Un solo target donde varias clases pueden ser ciertas simultáneamente.

Ejemplo: Género de película



- 1 target
- > 2 clases
- Clases no excluyentes
- Varias clases posibles por instancia

4. MULTI-TARGET (MULTI-OUTPUT)

Múltiples targets diferentes que se predicen simultáneamente.

Ejemplo: Paciente

Instancias	Targets (etiquetas)		
	Diabetes	Hipertensión	Obesidad
	Sí	No	Sí
	No	Sí	No
	Sí	Sí	No

Clases posibles por target:
- Diabetes: {Sí, No}
- Hipertensión: {Sí, No}
- Obesidad: {Sí, No}

- > 1 target
- Cada target tiene sus propias clases
- Predicción conjunta

5. RESUMEN COMPARATIVO

Tipo	Nº Targets	Nº Clases por target	¿Varias clases simultáneas?
Binario	1	2	No
Multiclase	1	> 2	No
Multietiqueta	1	> 2	Sí
Multi-target	> 1	Variable	Depende del target

IDEA CLAVE: Target = lo que se predice | Clase = valores posibles del target | Etiqueta = valor real de cada instancia

Tipo de Problema de Clasificación

- **Cardinalidad del target:**
  - *Binaria:* dos clases 

  - *Multiclase:* más de dos clases 

  - *Multietiqueta:* múltiples targets binarios 

  - *Multioutput:* múltiples targets, de cualquier cardinalidad.

- **Estructura del target:**
  - *Escalar:* un solo target de salida
  - *Vectorial:* múltiples targets de salida
  - *Secuencial:* una secuencia de etiquetas
  - *Jerárquica:* clases organizadas en niveles

- **Naturaleza de las clases:**
  - *Nominales:* sin orden
  - *Ordinales:* con orden implícito
  - *Estructuradas:* relaciones entre clases (jerarquías o grafos)

Tipo de Problema de Clasificación

TARGET
Variable que el modelo debe predecir.

CLASE
Cada valor posible que puede tomar el target.

ETIQUETA (LABEL)
Valor de la clase que tiene una instancia específica.

1. BINARIO

Un solo target con dos models posibles.

Ejemplo: Fraude



- 1 target
- 2 clases
- Clases excluyentes
- Solo una clase posible por instancia

2. MULTICLASE

Un solo target con más de dos clases posibles. Solo una clase es posible por instancia.

Ejemplo: Color



- 1 target
- > 2 clases
- Clases excluyentes
- Solo una clase posible por instancia

3. MULTIETIQUETA (MULTI-LABEL)

Un solo target donde varias clases pueden ser ciertas simultáneamente.

Ejemplo: Género de película



- 1 target
- > 2 clases
- Clases no excluyentes
- Varias clases posibles por instancia

4. MULTI-TARGET (MULTI-OUTPUT)

Múltiples targets diferentes que se predicen simultáneamente.

Ejemplo: Paciente

Instancias	Targets (etiquetas)		
	Diabetes	Hipertensión	Obesidad
	Sí	No	Sí
	No	Sí	No
	Sí	Sí	No

Clases posibles por target:
- Diabetes: {Sí, No}
- Hipertensión: {Sí, No}
- Obesidad: {Sí, No}

- > 1 target
- Cada target tiene sus propias clases
- Predicción conjunta

5. RESUMEN COMPARATIVO

Tipo	Nº Targets	Nº Clases por target	¿Varias clases simultáneas?
Binario	1	2	No
Multiclase	1	> 2	No
Multietiqueta	1	> 2	Sí
Multi-target	> 1	Variable	Depende del target

IDEA CLAVE: Target = lo que se predice | Clase = valores posibles del target | Etiqueta = valor real de cada instancia

Tipo de problema de clasificación

Tipo de Clasificación	Métricas recomendadas		Notas / Consideraciones
Binary classification	Accuracy Precision Recall	F1-score ROC AUC PR AUC	Si hay **clase desbalanceada**, evita accuracy; mejor usar **F1-score**, **ROC AUC** o **PR AUC**.
Multiclass classification	Accuracy Precision / Recall / F1-score (macro, micro, weighted) Cohen's kappa- Confusion matrix		Usa **macro** para igual peso a todas las clases, **weighted** si hay desbalance; ROC AUC se generaliza con OVR.
Multilabel classification	Hamming loss Subset accuracy (exact match ratio) Precision / Recall / F1-score (micro, macro)- Jaccard score		Subset accuracy es **muy estricta**. Usar **F1 micro** cuando importa el rendimiento global sobre etiquetas.
Multiclass-multioutput classification	Accuracy por variable Macro / micro F1-score por salida Average per-output metric Confusion matrix por salida		Tratar cada salida como un problema multiclass separado, luego promediar métricas.
Multi-output classification	Exact match ratio Macro/micro-averaged F1 Hamming loss Label ranking loss (opcional)		Si hay variables de diferente cardinalidad (mix multilabel y multiclase), combinar métricas según el caso.

Tipo de problema de clasificación

Binary classification

*Clasificación con un target de salida que solo puede tomar dos clases mutuamente excluyentes. **Binarios**.*

targes: 1
Clases por target: 2
type_of_target: "binary"

Multilabel classification

Clasificación de múltiples targets **binarios**. Una instancia puede pertenecer a ninguna, una o varias clases a la vez.

targes: >1
Clases por target: 2 (0 o 1)
type_of_target: "multilabel-indicator"

Multiclass classification

Un target de salida con más de dos clases posibles mutuamente excluyentes.

targes: 1
Clases por target: >2
type_of_target: "multiclass"

Multi-output classification (multilabel y multiclass-multioutput)

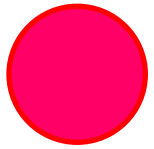
Predicción de múltiples targets categóricas (cada una puede ser binaria o multiclase).

targes: >1
Clases por target: 2 o más
type_of_target: "multiclass-multioutput" o "multilabel-indicator"

Ejercicio

- Precisar para su proyecto de investigación, a qué tipo de problema de clasificación corresponde.

- Precisar qué métrica de rendimiento usará para medir el desempeño de su proyecto.



ETIQUETADO DE DATOS

Etiquetado de Datos

El etiquetado de datos es el proceso mediante el cual se asignan metadatos descriptivos o interpretativos a elementos de un conjunto de datos con el fin de que puedan ser utilizados para entrenar, validar o probar modelos de inteligencia artificial y aprendizaje automático.

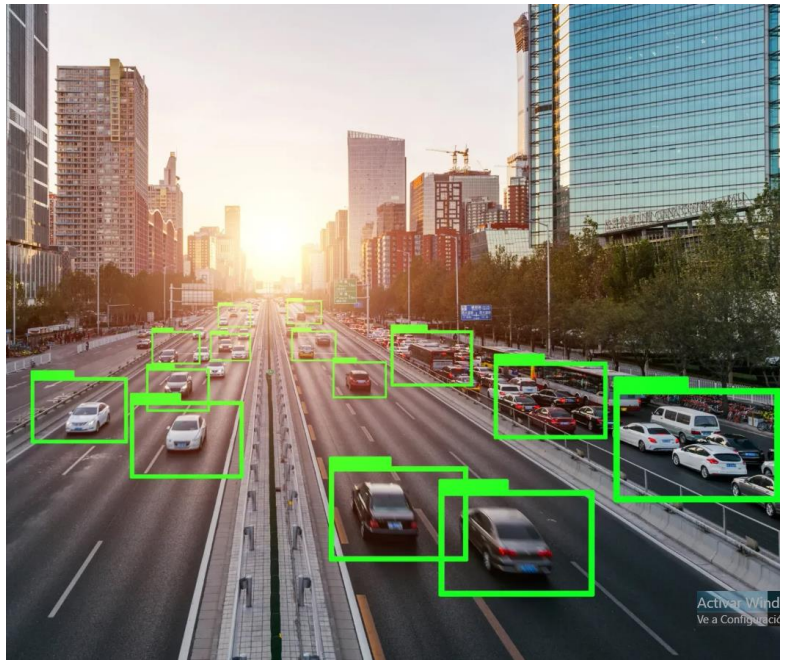
Esta tarea consiste en identificar, clasificar o delimitar información relevante dentro de los datos (que pueden ser imágenes, texto, audio, video, o datos tabulares) y asignarles una o más etiquetas que representen su contenido, contexto o significado.

Utilidad

- Los modelos de **aprendizaje supervisado** requieren ejemplos etiquetados para poder “aprender”.

- Las etiquetas actúan como una **guía o verdad objetiva** para que el algoritmo aprenda a realizar tareas como clasificación, detección, predicción o segmentación.

- **Sin etiquetas, el modelo no puede evaluar su propio rendimiento ni mejorar su precisión.**



- Además, el etiquetado de datos no solo es útil para entrenar modelos, sino también para:
  - Validar su rendimiento.
  - Comparar resultados entre modelos.
  - Realizar tareas de **detección de anomalías**, **extracción de características**, entre otros.

Técnicas de Etiquetado de Datos

- **Clasificación**
  - Se asigna una o más categorías a un dato.
    - Ejemplo: Un correo electrónico etiquetado como spam o no spam.
- **Segmentación (imagen o texto)**
  - Se etiqueta cada parte o píxel de un dato.
    - Ejemplo: En una imagen médica, etiquetar qué zona es tejido sano y cuál es un tumor.
- **Detección de entidades (NLP)**
  - Se marcan entidades específicas dentro de textos.
    - Ejemplo: En “Juan vive en Lima”, etiquetar Juan como persona y Lima como ciudad.
- **Reconocimiento de voz**
  - Se transcribe y etiqueta el contenido hablado en un audio.
    - Ejemplo: Etiquetar segmentos de audio con palabras, emociones o locutores.
- **Anotación de sentimientos**
  - Se asignan etiquetas emocionales o de opinión a un texto.
    - Ejemplo: Etiquetar una reseña como positiva, negativa o neutral.

Anotación de Datos

Es el proceso de agregar información adicional (anotaciones) a datos sin procesar para hacerlos comprensibles para los algoritmos de inteligencia artificial (IA) y aprendizaje automático (ML).

Estas anotaciones pueden incluir etiquetas, marcas, transcripciones, delimitaciones o descripciones detalladas, dependiendo del tipo de dato (imagen, texto, audio, video, etc.)

- **Labeling.** se enfoca en **asignar etiquetas o categorías específicas** a un dato (por ejemplo, "perro", "spam", "positivo").

- **Annotation.** puede incluir **más tipos de información contextual**, como:
  - Delimitación de objetos con cajas o polígonos en imágenes.
  - Transcripción de audio a texto.
  - Identificación de relaciones entre entidades en un texto.
  - Temporalidad (inicio y fin de un evento en video o audio).
  - Segmentación semántica o por píxeles.

Ejercicio

- Para su proyecto de investigación, ¿qué técnica usará?
- Si fuese etiquetado, este será hecho exante o expost?
- Si fuese anotación, precise que tipo de anotación.

REFERENCIAS

Referencias

1. Machi, L. A., & McEvoy, B. T. (2016). The Literature Review: Six Steps to Success. Corwin.

2. Hart, C. (2018). Doing a Literature Review: Releasing the Research Imagination (2nd ed.). Sage.

3. Booth, A., Sutton, A., & Papaioannou, D. (2016). Systematic Approaches to a Successful Literature Review (2nd ed.). Sage.

4. Fink, A. (2019). Conducting Research Literature Reviews: From the Internet to Paper (5th ed.). Sage.

5. Levy, Y., & Ellis, T. J. (2006). A Systems Approach to Conduct an Effective Literature Review in Support of Information Systems Research. Informing Science Journal, 9, 181–212.

PREGUNTAS

soportod@uni.edu.pe

Modelo de la Solución